Aprendizagem profunda de máquinas: conceitos, técnicas e bibliotecas.

William Reis Fernandes, Rodrigo Cezario da Silva
Faculdade Avantis
Curso de Bacharelado em Sistemas de Informação
Balneário Camboriú, SC, Brasil
{william.fernandes, rodrigo.cezario}@avantis.edu.br

RESUMO

A Aprendizagem Profunda, do inglês Deep Learning (DL) é uma divisão da Aprendizagem de Máquina que pesquisa técnicas para simular o comportamento do cérebro humano em tarefas como reconhecimento visual, reconhecimento de fala e processamento de linguagem natural. Algoritmos de aprendizagem profunda objetivam produzir representações hierárquicas de alto nível dos dados de entrada, por meio de categorias de processamento sequencial em uma rede neural artificial. Partindo desse princípio, este trabalho demonstra os fundamentos da aprendizagem profunda e apresentar 3 bibliotecas do mesmo: Tensorflow, Theano e Keras.

Palavras-chave
Aprendizagem profunda. Bibliotecas. Algoritmos. Tensorflow. Theano. Keras.

ABSTRACT

Deep Learning (DL) is a division of Machine Learning that researches techniques to simulate human brain behavior in tasks such as visual recognition, speech recognition, and natural language processing. Deep learning algorithms aim to produce high-level hierarchical representations of input data by means of sequential processing categories in an artificial neural network. Based on this principle, the present article intends to demonstrate the fundamentals of deep learning and to present 3 libraries of the same: Tensorflow, Theano and Keras.

Categories and Subjects Descriptors
Misc.; D.2 [Software Engineering]: Misc.

General Terms
IA. Machine Learning, Deep Learning.

Keywords
Deep Learning. Library. Algorithms. TensorFlow. Theano. Keras.

1. INTRODUÇÃO

A tecnologia chegou de maneira reservada em nosso cotidiano. Porém, dia após dia, tem marcado presença em nossas vidas, seja em nossa residência, ambientes corporativos, veículos ou nos aparelhos que utilizamos para comunicação como tablets, smartphones, aparelhos de televisão e videogames. A Inteligência Artificial ganhou importância e têm gerado grandes expectativas desde 2012, quando foi utilizada em uma competição de Visão por Computador denominada ImageNet, empregando-se a técnica de inteligência artificial Aprendizagem Profunda. [1]

A Aprendizagem Profunda é uma tecnologia ininterrupta de aprendizado de máquinas com elevada desempenho na resolução de problemas implexos e flexibilidade de aproveitamento de seus algoritmos. [2]. Dentre as principais aplicações estão o reconhecimento de imagens, voz e texto; a previsão de eventos e desenvolvimento de sistemas de recomendação, como tornar a experiência do cliente única e a detecção de fraudes.

A Aprendizagem Profunda oferece admiráveis prerrogativas na comparação

com metodologias clássicas de aprendizagem de máquina e, inclusive, ultrapassa a atuação humana em problemas que envolvem o diagnóstico de grandes volumes de dados não estruturados. [2]

O grande diferencial da Aprendizagem Profunda está na ocorrência de que o modelo criado é mais flexível na decisão do uso dos dados para que se tenha a melhor decorrência possível. Sendo assim, não se perde tanto tempo tentando descobrir quais inputs necessitam ser contidos, já que os modelos de Aprendizagem Profunda podem analisar todos os parâmetros e assim, definir a melhor combinação dos valores de entrada. Apesar de os conceitos matemáticos por trás da Aprendizagem Profunda estarem entre nós há muito tempo, bibliotecas de programação de computadores destinadas a criar e treinar os modelos de Aprendizagem Profunda surgiram apenas nos últimos anos, e muitas delas possuem verdadeiros desafios entre flexibilidade e possibilidade de uso.

Bibliotecas flexíveis são extraordinárias para pesquisa e desenvolvimento de novas arquiteturas, mas não estão acabadas para uso em produção com aplicações críticas de sistemas web por exemplo. Por outro lado, existem bibliotecas rápidas e eficientes para execução em ambiente paralelo e difundido (e, portanto, excelentes alternativas para o ambiente de produção), mas que são especializadas em apenas alguns tipos de redes neurais e possuem pouca flexibilidade. [3]

Isso cria um desafio na escolha entre qual biblioteca escolher para um projeto de Inteligência Artificial por exemplo.

Este trabalho está estruturado da seguinte forma: na Seção 2, é apresentada a fundamentação teórica. A Seção 3, apresentada a metodologia de Pesquisa utilizada. Na Seção 4 são apresentadas bibliotecas de aprendizagem profunda. A Seção 5 sintetiza os resultados na comparação das bibliotecas estudadas. E por fim, a Seção 6 apresenta as conclusões deste trabalho.

2. FUNDAMENTAÇÃO TEÓRICA

Esta seção apresenta as referências nas quais se norteia este trabalho.

Parte-se de uma breve explicação sobre o Aprendizagem Profunda como área da Aprendizagem de Máquinas, conclui-se com as características de 3 bibliotecas usadas em Aprendizagem Profunda.

2.1. A APRENDIZAGEM PROFUNDA DENTRO DA APRENDIZAGEM DE MÁQUINAS

Dentro da Inteligência Artificial temos a área de Aprendizagem de Máquina. [4] Esse é um campo da ciência da computação que evoluiu bastante a partir do estudo de reconhecimento de padrões (“*pattern recognition*”) e da teoria da aprendizagem computacional em inteligência artificial. A aprendizagem de máquina tem uma ligação “particular” com o Big Data pois é a base da análise preditiva do inglês (“*predicitive analytics” or “predictive modelling*”). Uma divisão mais especializada da Aprendizagem de máquina que norteia este trabalho é a Aprendizagem Profunda. [5]

Conforme pode ser observado na Figura 1, apresenta a relação entre Processamento de linguagem natural do inglês (Natural Language Processing - NLP) e a relação com Aprendizagem de máquinas e Aprendizagem Profunda. Aprendizagem Profunda é uma das técnicas da área a Aprendizagem de máquinas. [16]

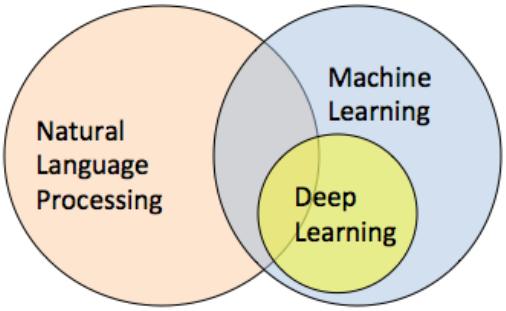

Figura 1. Relação entre NLP, ML e Deep Learning [16]
Fonte: [Dr. Rutu Mulkar-Mehta, 2016]

A ideia básica de que o software de Aprendizagem Profunda pode simular um grande arranjo de neurônios em uma "rede neural" artificial é bastante antiga e tem levado a tantas decepções como também a avanços.
Mas por causa das melhorias nas fórmulas matemáticas e nos computadores cada vez mais importantes, os cientistas de computação agora podem aumentar o número de camadas de neurônios virtuais do que anteriormente. [6].

2.1.1 TIPOS DE IMITAÇÃO NA APRENDIZAGEM PROFUNDA

Os tipos de imitação na Aprendizagem Profunda são baseados no trabalho de [7]. As máquinas observam um padrão e tentam imitá-lo de alguma maneira. Podem ser definidas como imitação direta e indireta como um paralelo aos dois tipos principais de aprendizado de máquinas: aprendizado de máquinas supervisionado e aprendizado automático sem supervisão [20].
O aprendizado automatizado da máquina é a imitação direta de um padrão entre dois conjuntos de dados. Isto é, sempre tentando capturar um conjunto de dados de entrada e transformá-lo em um conjunto de dados de saída. Essa pode ser uma capacidade incrivelmente poderosa e útil.

Os seguintes exemplos: (**entrada de conjuntos de dados em negrito** e *conjuntos de dados de saída em itálico*):

- Os **pixels** de uma imagem para detectar a *presença ou ausência de um gato, pixel é a menor unidade de uma imagem digital.*
- Os **filmes que o usuário gostou** para prever os *filmes que o usuário gostaria de ver.*
- As **palavras escritas** de alguém para prever se eles estão *felizes ou tristes*.
- Os **dados** de uma central climática prever a *probabilidade de chuva*.
- Os **sensores** do motor do carro para prever as *configurações de sintonia* ótimas.
- Os **dados** de notícias para prever o *preço* das ações de amanhã.
- Um **arquivo de áudio** bruto para prever uma *transcrição* do áudio.

Todas estas são tarefas supervisionadas de aprendizagem de máquinas. Em todos os casos, a aprendizagem da máquina algoritmo está tentando imitar o padrão entre os dois conjuntos de dados de tal forma que pode usar um conjunto de dados para prever o outro. [7]

2.1.2. APRENDIZADO DE MÁQUINA SUPERVISIONADA

A aprendizagem supervisionada é aquela que se destina a fornecer diretamente poder discriminativo para fins de classificação de padrões, frequentemente caracterizando as distribuições a posteriori de classes condicionadas aos dados visíveis. A aprendizagem supervisionada é um método para transformar um conjunto de dados em outro. [8]
Por exemplo, se tivemos um conjunto de dados de "Preços de ações de segunda-feira", que registrou o preço de cada ação em cada Segunda-feira nos últimos 10 anos, e um segundo conjunto de dados

de "preços de ações de terça-feira" registrado ao longo de no mesmo período de tempo, um algoritmo de aprendizagem supervisionado pode tentar usar um para prever o de outros [7].

2.1.3. APRENDIZADO DE MÁQUINA NÃO SUPERVISIONADA

Já a aprendizagem não supervisionada se destina a capturar a correlação de alta ordem dos dados observados ou visíveis para fins de análise ou síntese de padrões quando não há informações sobre os rótulos das classes disponíveis na base. Aprendizagem de representação não supervisionada na literatura refere-se a essa categoria de redes profundas. Quando usado no modo generativo, também pode-se buscar a caracterização de distribuições estatísticas conjuntas dos dados visíveis e suas classes associadas quando disponíveis, podendo ainda estas serem tratadas como parte dos dados visíveis. [8].

2.2. REDES NEURAIS DE APRENDIZAGEM PROFUNDA

As Redes Neurais Artificiais (RNA's) [18] consistem em uma gama de ferramentas que possuem a capacidade de aprender e se adaptar para a realização de certas tarefas através de um processo de aprendizagem. As habilidades de aprendizagem e adaptação indicam que os modelos de redes neurais podem lidar com dados imprecisos e situações que não foram totalmente definidas no início do treinamento. Por isso, o uso da inteligência artificial se torna cada vez mais atrativa em técnicas de processamento de imagem, reconhecimento de padrão, problemas de classificação, controle de processos, entre outros.

As RNA's tiveram início na década de 40, pelo neurofisiologista MacCulloch, do Instituto de Tecnologia de Massachussetts (MIT), e pelo matemático Waltter Pitts, da Universidade de Illinois, em que o trabalho realizado consistia em um modelo de resistores variáveis e amplificadores representando conexões sinápticas de um neurônio biológico. Desde então, diversos modelos de redes neurais têm sido desenvolvidos para aperfeiçoar e aumentar a aplicabilidade desta técnica em diversas áreas do conhecimento. [18]. Na Figura 2 é demonstrada uma arquitetura de rede neural simples.

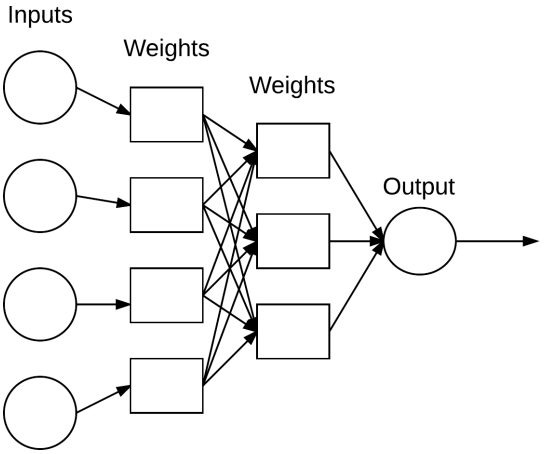

Figura 2. Uma arquitetura de rede neural simples. As entradas são apresentadas à rede. Cada conexão carrega um sinal através das duas camadas ocultas na rede. Uma função final calcula o rótulo da classe de saída. [19]

A classificação das técnicas de aprendizado profundo pode ser dividida em modelos discriminativos profundos ou em modelos generativos/não-supervisionados [9]. Dentre os discriminativos, são elencadas as Redes Neurais Profundas do inglês (*Deep Neural Network* - DNN), Redes Neurais Recorrentes do inglês (*Recurrent Neural Network* - RNN), Redes Neurais Convolucionais do inglês (*Convolutional Neural Network* - CNN), dentre outros. Quanto aos modelos generativos, destacam-se a Máquina Restrita de Boltzmann do inglês (*Restricted Boltzmann Machine* - RBMs), Máquinas Profundas de Boltzmann do inglês (*Deep Boltzmann Machines* - DBM), Redes

deep-belief, as redes auto- codificadoras regularizadas, etc. Entretanto, esse estilo de classificação bidirecional deixa escapar um conhecimento oriundo da pesquisa de aprendizagem profunda sobre como modelos generativos ou não supervisionados podem aprimorar bastante o desenvolvimento de DNN's e outros modelos de aprendizagem supervisionada através de melhor regularização ou otimização.

Além disso, as redes profundas para a aprendizagem não supervisionada podem não necessariamente serem probabilísticas ou avaliar uma amostra significativa do modelo. [9]

Segundo Szegedy et al (2015), as redes neurais convolucionais estão no centro da maioria das soluções de visão computacional para uma ampla variedade de tarefas. Desde 2014, as redes convolucionais muito profundas começaram a se tornar convencionais, produzindo ganhos substanciais em vários pontos de referência.

Embora o aumento do modelo e o custo computacional tendam a se traduzir em ganhos de qualidade imediatos para a maioria das tarefas (desde que dados suficientes sejam fornecidos para o treinamento) a eficiência computacional e a baixa contagem de parâmetros ainda são fatores facilitadores para vários casos de uso, como a visão móvel e cenários de grandes dados. Procurou-se modos de escalonar as redes de maneira que visem a utilização da computação adicionada, tão eficiente quanto possível, por convoluções fatorizadas [10].

2.2.1. REDES NEURAIS CONVOLUCIONAIS

A Rede Neural Convolucional é uma variante das Redes de Perceptrons de Múltiplas Camadas, tendo sido inspirada no método biológico de processamentos de dados visuais. De modo análogo aos processos clássicos de visão computacional, uma CNN (do inglês *Convolutional Neural Networks*) admite aplicar filtros em dados visuais, mantendo a relação de vizinhança entre os pixels da imagem ao longo do processamento da rede. A Figura 3 esboça uma matriz de pixel de uma imagem digital.

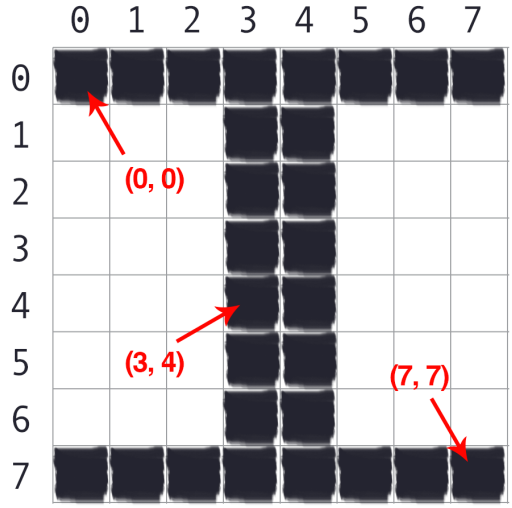

Figura 3. A letra "I" colocada em um pedaço de papel quadrado. Os pixels são acessados por suas coordenadas (x; y), onde x é a coluna para a direita e y para linhas [19].

A Figura 4 esboça uma CNN, este tipo de rede vem sendo vastamente utilizada, principalmente nas aplicações de categorização, detecção e importância em imagens e vídeos.

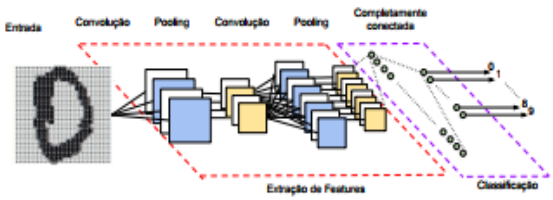

Figura 4. Exemplo de uma rede neural convolucional e suas diferentes camadas.
Fonte: [Vargas et al. 2016]

Uma rede neural convolucional incide em múltiplas partes com papéis diferentes. Inicialmente é comum aplicar sobre o

dado de entrada camadas ditas de convolução.

Uma camada de convolução é composta por múltiplos neurônios, cada um é responsável por aplicar um filtro em um pedaço característico da imagem. Podemos imaginar cada neurônio sendo conectado a um conjunto de pixels da camada anterior e que a cada uma dessa conexões se atribui um peso.

A combinação das entradas de um neurônio, utilizando os pesos concernentes de cada uma de suas conexões, gera uma saída ocorrida para a camada seguinte. Os pesos atribuídos às conexões de um neurônio podem ser decodificados como uma matriz que representa o filtro de uma convolução de imagens no domínio espacial (conhecido ainda como *kernel* ou máscara). Enquanto na formulação de Perceptrons clássica um neurônio é integrado a todos os neurônios da camada anterior, dito totalmente conectada, nas CNNs somente um subconjunto de entradas é conectado a cada neurônio. Com a transformação de arquitetura, as redes neurais convolucionais passam a realizar o diagnóstico de campos receptivos locais (*local receptive fields*). Os neurônios da mesma camada são coligados em mapas. Um mapa é produzido pelo agrupamento das saídas de neurônios que unidos cobrem uma parte da imagem que tenha sido processado com um filtro em comum. Para que um conjunto de neurônios de um determinado mapa utilize o mesmo filtro em distintas posições da imagem, é feito um compartilhamento dos pesos durante a técnica de treinamento.

Tal compartilhamento diminui expressivamente a quantidade de parâmetros a serem estudados e o tempo de treinamento da rede, por conseguinte. De modo a simplificar a esquematização dessas redes, um filtro a ser aplicado na imagem é constituído visualmente por somente um neurônio, causando a falsa sensação de que ele faria sozinho o procedimento de percorrimento da imagem. O tamanho do filtro determina a dimensão da vizinhança que cada neurônio da camada irá processar. Outra variável respeitável para a camada convolucional é o passo (ou *stride*). Este valor representa quantos pixels serão saltados entre cada janela, proferindo qual será a dimensão da camada subsequente na mesma unidade. Variavelmente do processo tradicional de Visão Computacional, no qual o padrão inicial parte da definição de filtros (ou *features*) a serem empregadas, nas camadas de convolução das CNNs é necessário determinar somente a arquitetura dos filtros: quantidade e tamanhos, passos, dos filtros por camada. O método de aprendizado da rede transforma os pesos ao longo do treinamento, até localizar os melhores valores dos filtros para o conjunto de dados empregado. Uma das maneiras de se avaliar o aprendizado é constatar as ativações dos filtros adquiridos ao fim do treinamento [11].

3. METODOLOGIA DE PESQUISA

Este trabalho quanto aos objetivos pode ser enquadrado como uma pesquisa exploratória. Quanto aos procedimentos técnicos, foi utilizado a pesquisa bibliográfica e pesquisa documental, sendo este a primeira etapa realizada. A primeira etapa, oportunizou conhecer os fundamentos de Aprendizagem Profunda. A segunda etapa oportunizou conhecer os fundamentos e pontos fortes e fracos das bibliotecas mais usadas em Aprendizagem Profunda.

4. BIBLIOTECAS DE APRENDIZAGEM PROFUNDA.

4.1. KERAS

Keras [François Chollet, 2015] é uma biblioteca de alto nível escrita em Python para criação de redes neurais. É capaz de usar as bibliotecas Theano [University of Montréal, 2009] [12] ou Tensorflow [Google Brain, 2015] [13]. Foi desenvolvida com o objetivo de diminuir o tempo de criação de redes neurais. Suporta redes neurais convolucionais e redes recorrentes, conectividade arbitrária de diversos tipos de redes neurais e pode rodar em com placa de vídeo [14]. Os pontos fortes da biblioteca Keras são apresentados na Tabela 1 e o pontos fracos na Tabela 2.

Tabela 1. Pontos fortes Keras

1	Fácil compreensão.
2	Tem como base duas outras bibliotecas que são o Theano e Tensorflow fazendo uso dos benefícios das duas.
3	Seu principio é orientado a: modularidade, minimalismo, extensibilidade.
4	Farta documentação da linguagem Python facilita seu uso.
5	Intuitivo, interface de alto nível
6	Keras tem apoio oficial do Google.

Tabela 2. Pontos fracos Keras

1	Baixa flexibilidade
2	Não possuí RPM por exemplo.
3	Menos projetos disponíveis online do que Theano e Tensorflow.
4	Multi-GPU não funciona 100%

4.2. TENSORFLOW

TensorFlow [Google Brain, 2015] [13] é uma biblioteca de código aberto para computação numérica e aprendizado de máquina disponibilizado pelo Google Brain Team em novembro de 2015. Essa biblioteca fornece implementação em múltiplas CPUs ou GPUs e é utilizada por diversas empresas. Sua farta documentação tornou uma das bibliotecas mais utilizadas para Deep Learning. Os pontos fortes da biblioteca Tensorflow são apresentados na Tabela 3. Os pontos fracos são apresentados na Tabela 4.

Tabela 3. Pontos fortes Tensorflow

1	Mantido/Apoiado pelo Google
2	Comunidade é muito grande
3	Interfaces de baixo nível e de alto nível para o treinamento em rede
4	Maior compilação de modelo do que as opções baseadas em Theano.
5	Suporte multi-GPU

Tabela 4. Pontos fracos Tensorflow

1	Em alguns teste se mostra mais lento do que as opções baseadas em Theano, embora o Tensorflow esteja se recuperando.
2	O suporte a RNN ainda está abaixo do Theano.

4.3. THEANO

Theano [University of Montréal, 2009] é uma biblioteca de computação numérica que alimenta muitas das outras bibliotecas de aprendizagem profunda existente, assim como Keras e Tensorflow que o presente artigo apresenta. Sua API é de baixo nível e para utilizar o Theano é necessário estar bastante familiarizado com os algoritmos que estão escondidos atrás de outras bibliotecas. Os pontos fortes são apresentados na Tabela 6 e os fracos na Tabela 7.

Tabela 6. Pontos fortes Theano

1	Flexível
2	Desempenho elevado, desde que bem usado

Tabela 7. Pontos fracos Theano

1	Curva de aprendizado substancial
2	API de baixo nível
3	A compilação de gráficos simbólicos complexos pode ser lenta.

5. RESULTADOS

A avaliação das bibliotecas demonstrou que existem cenários para cada uma, ou seja o uso de determinada biblioteca será melhor para determinada tarefa e nível de conhecimento, Theano é uma biblioteca de baixo nível e de grande flexibilidade, porém sendo de maior complexidade [12], Tensorflow é uma biblioteca de baixo e alto nível sendo seu uso de menor complexidade, porém se mostra mais lenta do que a Theano como vantagem tem como apoiador do projeto a Google o que faz sua evolução ser rápida [13], já a biblioteca Keras é de alto nível, ela abstrai das bibliotecas Theano e Tensorflow o poder e facilitar o desenvolvimento, porém de baixa flexibilidade por sua vez também apoiada pelo Google [15].

6. CONCLUSÕES

Redes profundas como as convolucionais e as recorrentes existem há vários anos, no entanto apenas recentemente modelos desenvolvidos com essas arquiteturas de redes começaram a apresentar resultado na comunidade cientifica, assim como o desenvolvimento de bibliotecas facilitadoras. Existe uma tendência no uso de bibliotecas especializadas que realizam, com eficiência e menor custo computacional, operações comuns em aprendizagem profunda que tirem proveito de hardware para treinamento.

Neste sentido, este trabalho teve como objetivo de apresentar os fundamentos da aprendizagem profunda, mais conhecido como Deep Learning. Por sua vez, foram apresentadas 3 bibliotecas amplamente citadas na literatura, o Tensorflow, Theano e Keras, onde são discutidos os pontos fortes e fracos de cada biblioteca. Além disso, este trabalho também apresentou um comparativo entre as bibliotecas apresentadas. Apesar do comparativo ser superficial, ele pode ajudar iniciantes na tecnologia na escolha da biblioteca para iniciar o desenvolvimento.

7. REFERÊNCIAS

[1] UNICAMP, Deep Learning é tecnologia de aprendizado de máquina que mais cresce em todo o mundo., Unicamp, 2017. Disponível em: <https://www.unicamp.br/unicamp/noticias/2017/10/02/deep-learning-e-tecnologia-de-aprendizado-de-maquina-que-mais-cresce-em-todo-o>, Acesso em: 29 outubro. 2017.

[2] COPELAND, MICHAEL What's the Difference Between Artificial Intelligence, Machine Learning, and Deep Learning?. Nvidia, 2016. Disponível em: <https://blogs.nvidia.com/blog/2016/07/29/whats-difference-artificial-intelligence-machine-learning-deep-learning-ai/>. Acesso em: 28 outubro. 2017.

[3] MATOS, DAVID, Deep Learning com Linguagem R – Parte 1 , Ciência e Dados, Disponível em: <http://www.cienciaedados.com/deep-learning-com-linguagem-r-parte-1/>, Acesso em: 24 outubro. 2017.

[4] Li Deng and Dong Yu. Deep learning: Methods and applications. Foundations and Trends® in Signal Processing, 2014.

[5] Richard O. Duda, Peter E. Hart, and David G. Stork. Pattern Classification (2Nd Edition). Wiley-Interscience, 2000.

[6] Itamar Arel, Derek C. Rose, and Thomas P. Karnowski. Research frontier: Deep machine learning–a new frontier in artificial intelligence research. Comp. Intell. Mag., 5(4):13–18, November 2010.

[7] Trask Andrew W. Grokking Deep Learning, pgs.11 – 17. MEAP Edition, 2017.

[8] Goodfellow, I., Bengio, Y., and

Courville, A. (2016). Deep Learning. MIT Press. http://www.deeplearningbook.org.

[9] Nanduri and Sherry 2016, Lipton et al. 2015, Goodfellow et al. 2016.

[10] Rethinking the Inception Architecture for Computer Vision <https://www.cv-foundation.org/openaccess/content_cvpr_2016/papers/Szegedy_Rethinking_the_Inception_CVPR_2016_paper.pdf>

[11]M. D. Zeiler and R. Fergus, Computer Vision – ECCV 2014: 13th European Conference, Zurich, Switzerland, September 6-12, 2014, Proceedings, Part I. Springer International Publishing, 2014, ch. Visualizing and Understanding Convolutional Networks, pp. 818–833.

[12] AL, J. B. E., “Theano: A CPU and GPU Math Compiler in Python”, http: //deeplearning.net/software/theano/, 2010, Accessed: 2016-5-5.

[13] AL., M. A. E., “TensorFlow: Large-scale machine learning on heterogeneous systems”, https://www.tensorflow.org/, 2010, Accessed: 2016-5-5.

[14] NICKOLLS, J., BUCK, I., GARLAND, M., et al., “Scalable Parallel Programming with CUDA”, Queue, v. 6, n. 2, pp. 40–53, Mar. 2008.

[15] Kovalev V., Kalinovsky A., and Kovalev S. Deep Learning with Theano, Torch, Caffe, TensorFlow, and deeplearning4j: which one is the best in speed and accuracy? In: XIII Int. Conf. on Pattern Recognition and Information Processing, 3-5 October, Minsk, Belarus State University, 2016, pp. 99-103.

[16] MULKAR-MEHTA , RUTU, Natural Language Processing vs. Machine Learning vs. Deep Learning, Dr. Rutu Mulkar-Mehta, Disponível em: <http://rutumulkar.com/blog/2016/NLP-ML>, Acesso em: 03 novembro. 2017.

[17] Szegedy, Christian; Vanhoucke, Vincent; Ioffe, Sergey; Shlens, Jonathon; Wojna, Zbigniew. Rethinking the Inception Architecture for Computer Vision. ARXIV. Dezembro, 2015.

[18] BENGIO, Y., COURVILLE, A., GOODFELLOW, I. Deep Learning. MIT Press, 1 a ed. 2016

[19] ROSEBROCK, ADRIAN, “Deep Learning For Computer Vision With Python”, pp. 122-126, 2017

[20] ROSEBROCK, ADRIAN, “Deep Learning For Computer Vision With Python”, pp. 45-47, 2017

[21] HAYKIN, S. (1999) Redes Neurais: Princípios e Prática. Artmed Editora S.A., 2a ed.